

2026 年（第十三届）英特尔杯大学生电子设计竞赛嵌入式 AI 专题赛

2026 Intel Cup Undergraduate Electronic Design Contest

- Embedded System Design Invitational Contest

作品设计报告

Final Report



Intel Cup Embedded System Design Contest

报告题目：基于边缘 AI 的骑手前向安全预警辅助系统

RiderGuardian: Edge AI-Based Forward Safety Warning System

学生姓名：陈姝漪、吴轩锋、甘炜成

指导教师：谢在鹏

参赛学校：河海大学

2026 年（第十三届）英特尔杯大学生电子设计竞赛

嵌入式 AI 专题赛

参赛作品原创性声明

本团队郑重声明：所呈交的参赛作品报告，是团队独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本项目不包含任何其他个人或集体已经发表或撰写过的作品成果，不侵犯任何第三方的知识产权或其他权利。本团队完全意识到本声明的法律结果由本团队承担。

参赛队员签名：

日期： 年 月 日

基于边缘 AI 的骑手前向安全预警辅助系统

摘要

针对外卖骑手配送中因查看导航、处理订单导致前向注意力分散、突发路况感知不足的问题，本文设计了一套基于 Intel DK-2500 的边缘 AI 骑手前向安全预警辅助系统。系统融合摄像头、毫米波雷达、IMU 与 GPS 等多源数据，在端侧完成道路目标识别、距离与姿态分析、速度判断和多模态风险融合，并通过震动实现分级预警。系统同时支持局域网实时可视化监测和关键风险数据留存，可为骑行安全管理、异常事件复盘和后续算法优化提供依据。本系统具有本地化处理、低延迟提醒和工程部署方便等特点，为即时配送骑行场景提供了一种主动安全辅助方案。

关键词：骑行安全，多模态融合，边缘计算，风险预警，Intel DK-2500

RiderGuardian: Edge AI-Based Forward Safety Warning System

ABSTRACT

Aiming at the problems of distracted forward attention and insufficient perception of sudden road conditions caused by checking navigation information and handling orders during food delivery, this paper designs an edge AI-based forward safety warning assistance system for riders based on Intel DK-2500. The system integrates multi-source data from a camera, millimeter-wave radar, IMU, and GPS. It completes road target recognition, distance and posture analysis, speed assessment, and multimodal risk fusion on the edge device, and provides graded warnings through vibration feedback. Meanwhile, the system supports real-time visual monitoring over a local area network and storage of key risk data, which can provide references for riding safety management, abnormal event review, and subsequent algorithm optimization. With local processing, low-latency warning, and convenient engineering deployment, the proposed system provides an active safety assistance solution for instant delivery riding scenarios.

Key words: riding safety, multimodal fusion, edge computing, risk warning, Intel DK-2500

目 录

第一章 绪论	1
1.1 项目背景与研究现状	1
1.2 Intel 硬件平台介绍	1
1.2.1 整体介绍	1
1.2.2 DK-2500 开发套件介绍	2
1.2.3 Core Ultra 5 225U 处理器与 Intel AI 开发生态	3
第二章 系统介绍	4
2.1 系统功能	4
2.1.1 开发目的	4
2.1.2 功能组成	4
2.1.3 应用场景	5
2.2 系统特点	5
第三章 系统方案设计	6
3.1 整体方案设计	6
3.2 硬件方案设计	7
3.2.1 设备端传感器选择和连接	7
3.2.2 硬件框图	11
3.2.3 实车部署与供电设计	12
3.3 软件方案设计	12
3.3.1 设备端的数据读取	13
3.3.2 核心推理层	13
3.3.3 本地反馈与云端监管	13
第四章 系统实现	16
4.1 前向视觉感知模型实现	16
4.1.1 可通行路面语义分割	16
4.1.2 动态障碍目标检测	17
4.1.3 基于 OpenVINO Runtime 的视觉模型端侧推理实现	17
4.1.4 视觉感知结果输出与接口设计	18
4.2 风险融合网络的设计	18
4.2.1 多源输入特征构建	19
4.2.2 时间对齐与缺失数据处理	19
4.2.3 风险融合网络结构	19
4.2.4 小结	21
4.3 风险融合网络训练与部署	21
4.3.1 风险样本构建与数据集划分	21
4.3.2 网络训练策略	21
4.3.3 端侧部署与功能验证	22
第五章 系统优化	23
5.1 边缘计算优化	23

5.1.1 多模态数据并行处理架构	23
5.1.2 异构计算资源协同调度	23
5.2 神经网络加速优化	24
5.2.1 模型量化与精度-性能权衡	24
5.2.2 基于 OpenVINO 的图优化与算子融合	24
5.2.3 内存零拷贝与数据传输优化	24
第六章 系统测试	25
6.1 测试方案设计	25
6.2 目标检测模型测试	25
6.2.1 目标检测模型精度评估	25
6.2.2 目标检测精度-性能权衡	26
6.2.3 目标检测硬件后端选型	26
6.3 道路分割模型测试	27
6.3.1 道路分割模型精度与选型	27
6.3.2 分割精度-性能权衡与硬件选型	28
6.4 推理框架优化验证	28
6.5 多模态融合有效性验证	29
6.6 模块性能与初步系统响应指标汇总	30
6.7 端到端风险预警有效性验证	30
6.8 测试结论	31
第七章 总结与展望	32
7.1 项目总结	32
7.2 未来展望	32
参考文献	33

第一章 绪论

1.1 项目背景与研究现状

近年来，随着即时配送业态快速发展，外卖骑手已成为城市交通系统中数量庞大、活动频繁的职业骑行群体。数据显示，2023 年我国即时配送订单量达到 420 亿单，配送用户规模逾 7 亿人次，2024 年订单规模预计超过 480 亿单^[1]。即时配送规模的扩大，使骑手安全逐渐成为城市低速交通安全中的重要问题。

与普通骑行者相比，外卖骑手在配送过程中需要同时关注导航路线、订单状态、平台提醒和道路环境。配送时效、连续接单和收入激励进一步增加了骑手的时间压力，使其更容易出现频繁查看手机、赶时间和注意力切换不足等情况。相关报道指出，平台算法压缩配送时间可能倒逼骑手采取超速、逆行、闯红灯等高风险行为，并增加疲劳送单风险^[2]。因此，骑手面临的危险并非单次偶然分心，而是高频配送任务、复杂道路环境和持续注意力负荷共同作用的结果。

在实际骑行中，前向道路风险对骑手安全影响最直接。前车急停、行人横穿、非机动车突然变道、路口障碍物逼近等情况通常具有突发性强、距离近、避让时间短的特点。因此，面向外卖骑手的安全辅助系统应重点解决前向连续感知被打断的问题，而不仅是事后记录或一般骑行提醒。

目前，骑行安全辅助产品已有一定基础。国外以 Garmin Varia 等产品为代表，主要面向自行车或电助力车的后向来车监测^[3]；国内部分方案则围绕后向防撞、盲区提醒、智能头盔和行车记录等方向展开。这些产品能够在一定程度上提升骑行安全性，但大多聚焦于后方来车或事故记录，对外卖骑手高频配送中的前向风险关注不足。同时，事故或异常事件发生后，普通视频记录和订单轨迹难以完整还原前方路况、骑行状态、障碍距离和预警情况，也不利于平台进行风险统计、事故回溯和安全管理。

此外，真实骑行场景对感知可靠性和响应速度提出了较高要求。单纯依靠摄像头容易受到逆光、弱光、遮挡和路面颠簸影响；单纯依靠毫米波雷达虽然能够稳定获取距离和相对速度，但对目标类别、可通行区域和环境语义的理解不足；仅使用 IMU 或 GPS 又难以直接判断前方障碍风险。因此，系统需要从单一传感器判断转向多模态协同感知，并在本地完成实时风险判断，减少网络延迟对预警效果的影响。

基于上述需求，本项目采用边缘计算和多源感知融合思路。系统面向外卖骑手前向安全场景，融合前向摄像头、毫米波雷达、IMU 和 GPS 等多源数据，结合 Intel 边缘计算平台与 OpenVINO 工具链，实现前向环境识别、风险融合判断、头盔震动预警和行程风险记录。

1.2 Intel 硬件平台介绍

1.2.1 整体介绍

本项目采用主办方提供的 Intel DK-2500 开发套件作为边缘计算平台^[4]。DK-2500 是一款面向嵌入式 AI 应用的开发套件，集成 Intel® Core™ Ultra 处理器、DDR5 内存、SSD 存储、Intel 图形单元以及丰富的外部与内部扩展接口，能够在较小体积内提供较强的通用计算、图形处理和外设连接能力。

与传统单片机或轻量级嵌入式开发板相比，DK-2500 的优势在于能够运行完整操作系统，并支持主流 AI 开发环境和推理工具链。该平台既具备嵌入式设备体积紧凑、接口丰富、便于部署的特点，又具备边缘计算主机的综合计算能力，适合视觉感知、多源数据处理、实时控制和边缘智能等应用场景。




图 1-1 DK-2500 开发套件实物图

1.2.2 DK-2500 开发套件介绍

DK-2500 开发套件搭载 Intel® Core™ Ultra 5 Processor 225U。该处理器基础功耗为 15W，最高频率可达 4.8GHz，具备 12 核 14 线程的计算资源，能够为多线程任务、传感器数据处理和边缘端 AI 推理提供较好的性能基础^[5]。相较于仅面向控制任务的低功耗处理器，Core Ultra 5 225U 更适合承担嵌入式 AI 系统中“感知、计算、决策、控制”并行运行的综合负载。

在存储与运行资源方面，DK-2500 配备 16G DDR5 内存和 128G SSD。DDR5 内存能够为模型推理、图像处理和多线程程序运行提供较好的数据带宽，SSD 则可用于存放系统程序、模型文件、测试数据和运行日志，为系统开发与调试提供稳定的存储环境。

在接口配置方面，DK-2500 提供 HDMI、DP、eDP/LVDS 等显示接口，支持多种调试与显示方式；提供 4 路 Intel i210 千兆以太网接口和 4 个 USB3.2 接口，便于高速外设接入和网络通信；同时提供 GPIO、PWM、UART、I2C、I2S、GSPI 等扩展信号，能够满足嵌入式系统中常见的数据采集、设备通信和执行控制需求。丰富的接口资源使 DK-2500 不仅适合模型推理任务，也适合构建完整的边缘智能原型系统。

表 1-1 DK-2500 开发套件主要硬件参数

硬件项目	主要参数	平台优势
处理器	Intel® Core™ Ultra 5 Processor 225U	提供较强 x86 通用计算能力
核心与线程	12 核 14 线程，最高 4.8GHz	支持多任务并发处理
内存	16G DDR5	支撑模型推理与数据缓存
存储	128G SSD	便于部署系统、模型和测试数据
图形单元	Intel® Graphics	支持图像处理与推理加速
网络接口	4 路 Intel i210 GbE LAN	支持高速通信和系统扩展

硬件项目	主要参数	平台优势
外设接口	4 个 USB3.2	便于连接高速外设
扩展接口	GPIO、PWM、UART、I2C 等	支持传感器通信和控制输出
操作系统	Windows 10/11, Ubuntu 20.04/22.04	兼容主流开发与部署环境

1.2.3 Core Ultra 5 225U 处理器与 Intel AI 开发生态

DK-2500 开发套件搭载的 Intel® Core™ Ultra 5 Processor 225U 属于 Intel Core Ultra 系列。该处理器面向移动计算与边缘智能场景，采用混合核心架构设计，具备最高 4.8GHz 运行频率和 14 线程计算能力，能够在较低基础功耗下提供较强的多任务处理性能。




图 1-2 Intel Core Ultra 5 Processor 225U 特性示意图

Core Ultra 5 225U 的重要特点在于集成了 CPU、GPU 和 NPU 等异构计算资源。其中，CPU 适合承担系统调度、通用逻辑处理和多线程任务；集成图形单元可用于图像处理、视频处理和视觉推理等并行计算任务；NPU 则面向低功耗 AI 推理场景，可在后续系统优化中承担部分神经网络计算任务。相比单一计算单元平台，这种异构架构有助于在性能、功耗和实时性之间取得更好的平衡。

除处理器硬件能力外，Intel 平台还提供较完整的 AI 开发与优化生态。OpenVINO 工具套件支持将 PyTorch、TensorFlow、ONNX 等框架训练得到的模型部署到 Intel CPU、GPU、NPU 等硬件单元上运行^[6]；oneAPI、VTune Profiler 等工具可用于异构程序开发、性能分析和系统瓶颈定位。这些软硬件资源为嵌入式 AI 系统的模型部署、性能调优和工程落地提供了良好支撑。

总体来看，DK-2500 以 Core Ultra 5 225U 为核心，兼具 x86 通用计算能力、异构 AI 推理能力、丰富 I/O 接口和主流开发生态，适合作为本项目的边缘计算平台。

第二章 系统介绍

2.1 系统功能

2.1.1 开发目的

本项目旨在设计一套面向骑手骑行过程的前向安全预警辅助系统。系统重点解决骑手在配送过程中因查看导航、处理订单或注意力切换不及时而造成的前方风险感知不足问题，为骑行过程提供主动、及时、低干扰的安全提醒。

本系统并不替代骑手完成驾驶决策，而是作为一种辅助感知与提醒装置，在前方环境出现潜在危险时，结合道路环境、障碍距离、骑行姿态和速度状态进行综合判断，并通过震动方式提示骑手及时关注前方道路。系统还记录骑行过程中的关键风险数据，为事故回溯、运行分析和后续算法优化提供依据参考；在接入配送平台管理端后，也可用于骑行安全监管、风险行为统计和事故过程分析参考。

2.1.2 功能组成

本系统以 Intel DK-2500 开发套件作为边缘计算平台，配合前向视觉感知设备、毫米波雷达、IMU、GPS 模块和震动预警模块等外设硬件，构成面向骑行前方安全风险的嵌入式 AI 辅助系统。系统整体功能可概括为“前向感知、状态采集、风险融合、触觉预警、行程记录”五个部分：首先采集骑行方向上的道路环境和车辆状态信息，然后在边缘端完成数据处理与风险判断，最后根据风险等级输出震动提醒，形成从感知输入到预警输出的闭环。




图 2-1 系统功能组成框图

其中，前向环境感知用于判断骑行路径中是否存在行人、车辆、障碍物等风险目标；骑行状态采集用于反映当前车辆运动状态；风险融合决策将多源信息转化为统一的风险等级；预警执行模块根据风险等级输出不同形式的头盔震动反馈；行程记录用于保存关键运行数据，并支持网页端实时查看。

2.1.3 应用场景

本系统面向外卖配送、同城跑腿、生鲜配送等即时配送骑行场景，适用于骑手频繁查看导航、接收订单提醒或在复杂道路中高频通行的情况。使用时，骑手将前向感知模块固定在车把、车头等朝向骑行方向的位置，将震动模块集成在头盔内侧或其他易感知位置；系统启动后，DK-2500 自动加载感知模型和采集程序，进入实时监测状态。

骑行过程中，系统持续采集前方道路、障碍物距离、车身姿态和速度信息。道路安全时保持静默，避免干扰；当前方出现行人横穿、前车急停、障碍物逼近或可通行区域变窄等情况时，系统综合视觉、距离和骑行状态判断风险等级，并通过不同强度或节奏的头盔震动提醒骑手。同时，系统记录图像、位置、速度、姿态、距离和风险结果，支持网页实时显示、事故回溯、骑行监管、异常统计和责任辅助认定，提升配送安全管理规范化水平。

2.2 系统特点

（1）充分发挥 Intel 边缘平台算力优势

本系统以 Intel DK-2500 开发套件作为边缘计算核心，利用其 x86 通用计算能力、Intel 图形单元和完整操作系统环境，承担前向感知、数据处理、风险判断和执行控制等任务。与仅依赖单片机或轻量级开发板的方案相比，该平台能够更好地支撑视觉模型推理、多传感器数据处理和多线程程序运行，为系统实时预警提供较稳定的计算基础。

（2）实时性强，降低对网络环境的依赖

骑行安全预警对响应速度要求较高，若依赖云端传输和远程计算，网络波动可能影响预警效果。本系统将核心感知与风险判断部署在本地边缘端完成，使风险识别和震动提醒能够在本地闭环内完成，减少对网络环境的依赖。该方式更适合前向碰撞预警这类对延迟敏感的移动场景。

（3）多源信息融合，提高风险判断可靠性

系统不是单独依赖某一种传感器完成判断，而是综合利用视觉、距离、姿态和速度等多类信息。视觉感知能够提供目标类别和道路语义信息，距离感知能够补充目标远近和接近趋势，IMU 与 GPS 信息则反映骑行状态。多源信息之间可以形成互补，有助于降低单一传感器在光照变化、遮挡、颠簸或目标识别不稳定情况下带来的判断误差。

（4）头盔触觉预警，交互方式低干扰

本系统采用头盔震动作为主要预警方式。相比屏幕提醒，震动反馈不会额外占用骑手视觉注意力；相比声音提醒，震动反馈不容易受到道路噪声影响。系统可根据风险等级输出不同强度或节奏的震动信号，使骑手在不频繁查看屏幕的情况下感知危险程度，更适合骑行过程中的即时安全提醒。

（5）行程风险记录，支持事故回溯

系统不仅进行实时预警，还记录图像、位置、速度、姿态、雷达距离、风险评分和预警触发时刻等关键数据。相关数据可通过网页显示，并在事故或异常事件后用于过程回溯；在授权接入管理端后，也可为配送安全管理提供数据支持。

（6）结构清晰，具备较好的扩展与部署能力

系统由感知输入、边缘计算、风险决策和预警输出等部分组成，模块边界清晰，便于后续调试和扩展。传感器、计算平台和预警执行模块可根据实际安装条件进行组合调整，后续也可继续扩展更多传感器或更精细的风险判断策略。因此，该系统不仅能够用于当前骑手前向预警场景，也具备向校园巡逻车、共享电动车、园区低速车等短途移动安全场景扩展的潜力。

第三章 系统方案设计

3.1 整体方案设计

本系统由感知层、边缘计算层、风险决策层、执行反馈层和云端监管层五部分组成，各层之间按照“数据采集—边缘处理—风险判断—执行反馈—云端记录与监管”的流程依次连接，形成完整的骑行安全预警与监管系统框架。




图 3-1 系统架构图

本系统在硬件方面，主要以官方提供的英特尔 DK-2500 开发套件作为核心计算平台，外围接入 WT61C 姿态传感器、NEO-M8N-0-10 GPS 模块、LD2417 毫米波雷达、Logitech C910 相机以及震动马达与其驱动等模块，实现了多源数据采集、端侧智能推理、分级预警反馈以及云端日志存储。

在边缘计算层，DK-2500 平台负责完成数据接入、预处理、时间同步和数据结构化。相机采集到的道路画面首先经过目标识别和语义分割处理，提取行人、车辆、障碍物、可行驶区域和视觉风险特征；IMU、GPS 和毫米波雷达数据则分别转化为姿态特征、速度位置特征和目标距离特征。通过端侧预处理，系统能够将原始传感器数据转换为适合后续风险判断的统一特征表达。

在风险决策层，本系统设计了多模态风险融合网络。该网络以 IMU 姿态数据、GPS 速度与位置信息、毫米波雷达目标状态，以及目标识别和语义分割后得到的视觉语义特征作为输入，通过独立特征编码、跨模态信息融合和风险回归输出等过程，学习车辆自身状态、道路环境、前方目标分布和运动趋势之间的复杂关联关系，最终输出连续的综合风险值。

在执行反馈层，系统根据风险等级驱动震动马达产生不同强度或模式的触觉提醒，使骑手能够在不分散视觉注意力的情况下及时感知潜在危险。相比单纯依靠声音或屏幕提示的方

式，触觉反馈更加适合骑行场景，能够增强预警的即时性和实用性。

为增强系统的可视化调试与监管能力，本系统设计了本地实时 Dashboard 与云端数据留存两级数据服务。实时 Dashboard 部署在 DK-2500 边缘端或同一局域网服务器中，管理人员可通过浏览器访问，查看摄像头画面、车辆姿态、速度信息、雷达目标状态、视觉识别结果、风险评分、预警等级和传感器工作状态等内容。

同时，系统将关键骑行数据上传至云端数据库进行留存，包括骑手编号、时间戳、经纬度、速度、姿态状态、雷达距离、视觉识别结果、风险评分和预警触发记录等。对于骑行视频数据，系统不直接将完整视频持续上传至云端数据库，而是采用“普通片段滚动缓存、高风险片段标记留存”的方式处理：普通骑行视频仅在本地或服务器指定目录中短时缓存，并按时间窗口自动覆盖；当系统检测到高风险预警或疑似事故时，才对相关时间段的视频片段进行标记，并在数据库中保存视频路径、起止时间、对应骑行记录编号和风险等级等索引信息，便于后续进行骑行过程复盘和安全管理分析。

综上，本系统将端侧实时预警、风险融合网络、局域网可视化监管和云端数据留存有机结合，既能在骑行过程中为骑手提供及时有效的安全提醒，又能为管理人员提供实时监测手段，并在事故发生后提供相对完整、客观的数据依据，具备较强的实时性、鲁棒性、可扩展性和实车部署价值。

3.2 硬件方案设计

3.2.1 设备端传感器选择和连接

(1) WT61C 姿态传感器。

在三维空间中运动的物体，其运动状态通常可以分解为质心的平动和绕质心的转动。对于电动车骑行场景而言，车身的加速度变化、角速度变化以及姿态角变化能够较好反映车辆的运动稳定性。因此，利用姿态传感器采集车辆运动状态信息，可以为系统判断急刹、颠簸、侧倾和异常姿态变化提供重要依据。

本项目采用 WT61C 姿态传感器作为车辆状态感知模块。WT61C 是一种基于 MEMS 技术的六轴姿态测量传感器，内部集成三轴加速度计和三轴陀螺仪，可实时测量三轴加速度、三轴角速度以及姿态角等数据^[17]。该传感器内部具备姿态解算与滤波处理能力，能够将原始惯性测量数据转换为较为直观的横滚角、俯仰角、偏航角等姿态信息，并通过串口方式输出至主控平台。与仅输出原始加速度或角速度的传感器相比，WT61C 能够降低上位机端的数据解算压力，使 DK-2500 平台可以更专注于多源数据融合、视觉推理和风险决策等任务。

在本项目中，WT61C 主要用于采集电动车骑行过程中的姿态变化和运动冲击信息。当车辆出现急刹、快速转向、路面颠簸或车身明显倾斜时，传感器输出的加速度、角速度和姿态角会发生相应变化。系统通过读取这些数据，可以判断车辆当前运动状态是否稳定，并将其作为前向风险判断的辅助输入。该模块与摄像头、毫米波雷达和 GPS 模块形成互补关系，使系统不仅能够感知外部道路环境，也能够获取车辆自身运动状态，从而提高整体判断的可靠性。

本项目选用 WT61C 姿态传感器，主要基于以下优点：

1. 传感器集成三轴加速度计和三轴陀螺仪，能够同时输出加速度、角速度和姿态角信息，适合用于电动车骑行过程中的姿态监测与稳定性分析。
2. 模块内部具备姿态解算和滤波处理能力，可减少原始惯性数据噪声对判断结果的影响，提高车身状态识别的稳定性。
3. 传感器体积较小、安装方便，可固定于电动车车架主干或靠近车辆质心的位置，适合在实车平台中进行长期采集与调试。
4. WT61C 支持串口通信，便于与 DK-2500 平台进行数据连接和程序读取，有利于后

续完成多传感器同步采集和系统联调。

在本项目中,我们使用了 TTL-USB 转接线实现了 WT61C 模块与 DK-2500 主板的连接。




图 3-2 WT61C 姿态传感器结构图

WT61C 姿态传感器重要参数:

表 3-1 WT61C 姿态传感器重要参数表

参数	条件	典型值
加速度计量程		$\pm 16g$
加速度计分辨率		0.0005 g/LSB
加速度计 RMS 噪声	带宽=100Hz	0.75~1mg-rms
加速度计静止零漂	水平放置	$\pm 20 \sim 40mg$
加速度计温漂	$-40^{\circ}C \sim +85^{\circ}C$	$\pm 0.15mg/^{\circ}C$
加速度计带宽		5~256Hz
陀螺仪量程		$\pm 2000^{\circ}/s$
陀螺仪分辨率	$\pm 2000^{\circ}/s$	0.061($^{\circ}/s$)/(LSB)
陀螺仪 RMS 噪声	带宽=100Hz	0.028~0.07($^{\circ}/s$)-rms
陀螺仪静止零漂	水平放置	$\pm 0.5 \sim 1^{\circ}/s$
陀螺仪温漂	$-40^{\circ}C \sim +85^{\circ}C$	$\pm 0.005 \sim 0.015 (^{\circ}/s)/^{\circ}C$
陀螺仪带宽		5~256Hz

(2) NEO-M8N-0-10 GPS 模块

NEO-M8N-0-10 GPS 模块是 u-blox M8 系列中的高性能 GNSS 定位模块,可同时接收和处理多种卫星导航系统信号,能够为移动设备提供位置、速度、时间等基础导航信息^[18]。与传统单 GPS 接收模块相比,NEO-M8N-0-10 支持多星座联合定位,可在开阔道路、城市道路等不同环境下提高搜星能力和定位稳定性。该模块具有体积小、功耗较低、接口丰富和集成度高等特点,常用于车辆定位、无人机导航、移动机器人、运动轨迹记录和嵌入式导航系统等场景。




图 3-3 GPS 模块结构图

在本项目中，NEO-M8N-0-10 主要用于获取电动车当前行驶速度和位置信息，为系统判断车辆运动状态提供辅助数据。NEO-M8N-0-10 通过串口与 DK-2500 平台连接，系统可解析其输出的 NMEA 或 UBX 数据，从中提取速度、经纬度、卫星数量和定位状态等信息^[18]。该模块的引入使系统不仅能够感知外部环境和车身姿态，还能够掌握车辆的整体运动状态，从而进一步增强多模态风险融合的完整性和可靠性。

（3）LD2417 毫米波雷达

LD2417 毫米波雷达是一款面向车辆状态检测场景的 24GHz 雷达模组，采用 FMCW 调频连续波技术，通过发射和接收电磁波信号，对探测范围内的目标进行距离、速度和方向等信息测量。与视觉传感器相比，毫米波雷达不依赖环境光照，能够在逆光、弱光、夜间等条件下保持较稳定的探测能力，适合作为骑行安全预警系统中的物理距离感知模块。

LD2417 模块支持串口通信，便于接入 DK-2500 平台进行数据读取和解析；同时，其供电范围较宽，适合在电动车实车平台中配合稳压模块使用。由于该模块主要输出结构化目标信息，上位机无需对原始雷达回波进行复杂处理，有利于降低系统开发难度和实时计算压力。




图 3-4 雷达模块结构图

本项目将 LD2417 毫米波雷达安装于电动车前向位置，用于获取前方目标的距离和相对运动信息。雷达数据主要承担两方面作用：一是为前方障碍物提供相对稳定的距离信息，弥补视觉模型在复杂光照或局部遮挡条件下的不足；二是提供目标接近趋势和速度变化信息，为系统判断前车急停、障碍物逼近等风险场景提供依据。

LD2417 模块重要参数：

表 3-2 LD2417 模块重要参数表

参数	条件	典型值
供电电压		5~12V
探测距离	可配置	2~100m
通信接口		UART、GPIO

(4) Logitech C910 相机

Logitech C910 是一款 USB 高清摄像头，可作为本项目的前向视觉感知模块，用于采集电动车行驶过程中的道路图像和前方交通环境信息^[19]。该摄像头采用有线 USB 2.0 接口连接，支持 UVC 标准，能够较方便地接入 DK-2500 平台，并通过 OpenCV 等视觉处理程序完成图像读取。C910 具备玻璃镜头和自动对焦能力，可在一定范围内获得较清晰的前向图像^[19]，为后续目标检测、行人识别、车辆识别和可行驶区域判断提供视觉输入。



图 3-5 相机实体图

在本项目中，摄像头安装于电动车车头或车把前方位置，使其视场方向与车辆行驶方向基本一致，从而覆盖前方道路、行人、非机动车和机动车等典型目标。由于 C910 本身不具备主动测距能力，因此其采集的视觉信息主要用于目标识别和场景理解，目标距离、相对速度等物理量则由 LD2417 毫米波雷达进行补充。

Logitech C910 重要参数：

表 3-3 Logitech C910 重要参数表

参数	条件	典型值
USB 类型		High Speed USB 2.0
UVC 支持		支持
视频采集分辨率	16:9	1080p
最大帧率	640x480	30fps
光学分辨率		5MP
图像增强		Right Light 2

(5) 马达及其驱动模块

2V-091640 线性震动马达是本系统的触觉反馈执行器，额定工作电压为 2V，震动量约为 4G，可将系统输出的风险预警信号转化为骑手能够直接感知的震动提醒。与蜂鸣器和屏幕提示相比，震动反馈不占用骑手视觉与听觉通道，更适合骑行过程中的安全预警场景。



图 3-6 马达实体图

DRV2605 是用于驱动震动马达的触觉反馈驱动模块,可通过 I2C 接口接收主控平台指令,并对马达的启动、停止、震动强度和震动模式进行控制^[20]。在本项目中,DK-2500 根据风险等级向 DRV2605 输出控制指令,由 DRV2605 驱动 2V-091640 线性震动马达产生不同强度或节奏的触觉反馈,从而实现低干扰、分级化的安全预警输出。



图 3-7 驱动模块实体

3.2.2 硬件框图

系统的硬件框图如图 3-8 所示。




图 3-8 系统硬件框图

本系统硬件部分以英特尔 DK-2500 开发套件为核心，前向相机通过 USB 接口接入 DK-2500，用于采集道路图像；LD2417 毫米波雷达通过串口接入，用于获取前方目标距离与相对运动信息；WT61C 姿态传感器用于采集车身加速度、角速度和姿态角；GPS 模块用于提供车辆速度与定位信息。上述感知数据在 DK-2500 平台完成本地汇聚、解析和处理后，系统根据风险判断结果通过 I2C 接口控制 DRV2605 驱动模块，再由驱动模块带动 2V-091640 线性震动马达产生触觉反馈。

3.2.3 实车部署与供电设计

为支持系统能够从实验室原型进一步过渡到实车骑行测试，本项目对各硬件模块的安装位置、固定方式、供电方式和工程注意事项进行了统一设计。部署时优先保证前向感知角度稳定、线束不影响骑行操作、核心计算平台具备散热空间，并通过扎带、支架和固定盒对传感器与线缆进行防震固定。

表 3-4 实车部署与供电设计

模块	安装位置	固定方式	供电方式	工程注意事项
DK-2500	车篮、后座或 车身中部	防震支架、扎 带或固定盒	独立电池包或 电动车降压模 块	散热、防水、 防震、线束固 定
摄像头	车把正前方	可调角度支架	USB 供电	视场角、抖动 和遮挡
毫米波雷达	车头前向位置	固定支架	5V/12V 供电	朝向、离地高 度和前方遮挡
IMU	车架主梁或靠 近车身稳定位 置	胶贴或螺丝固 定	USB/串口模块 供电	避免安装在强 振动或易松动 位置
GPS	车头上方无遮 挡处	胶贴或小支架 固定	串口接入	避免金属遮 挡，保证搜星
震动马达	头盔内侧或车 把握持处	胶贴或嵌入式 固定	DRV2605 驱动	保证骑手可明 显感知且不影 响佩戴

在供电设计上，DK-2500 与传感器模块优先由独立电源或电动车降压模块供电，避免与车辆原有控制系统共用不稳定电源；摄像头通过 USB 接入，IMU、GPS、雷达和马达驱动通过 USB、串口和 I2C 转接方式接入。实车布线时，所有线缆沿车架固定并预留转向余量，避免刹车、转向或颠簸时拉扯接口。

3.3 软件方案设计

本软件方案采用多传感器融合架构，通过改进后的 Yolo26n-v2 和 road-segmentation-adas-0001 模型对实时采集的画面进行目标识别与行驶路面的语义分割，输出视觉风险特征数据。再将视觉的风险特征数据与毫米波雷达、IMU 姿态传感与 GPS 在边缘端进行时空同步与特征提取，送入风险融合网络，输出风险值。

根据风险等级，系统通过震动马达向骑手进行本地实时预警。与此同时，系统在 DK-2500 边缘端维护本地状态池，并通过 WebSocket 与 MJPEG 视频流向局域网内的 Web Dashboard 推送实时状态和摄像头画面，用于管理端实时查看。对于需要长期保存的关键骑行数据，系统再通过 WiFi 上传至云端数据库，用于历史记录查询、风险统计分析和事故场景回溯。




图 3-9 软件设计流程图

3.3.1 设备端的数据读取

设备端针对 IMU、GPS、毫米波雷达和摄像头四类传感器分别设计独立的数据读取模块，各模块按照统一接口运行，完成数据采集、协议解析、时间戳标注和有效性判断。IMU 模块读取姿态角、加速度和角速度等运动数据；GPS 模块获取定位坐标、速度和卫星状态；毫米波雷达模块采集前方目标距离、相对速度等信息；摄像头模块持续读取道路图像帧，为后续目标识别和语义分割提供输入。

3.3.2 核心推理层

核心推理层主要承担多源感知信息的智能分析与风险判断任务。系统首先将摄像头采集的道路图像输入目标识别模型，识别画面中的行人、车辆、障碍物等关键目标，并提取其类别、数量和位置等信息；随后将图像送入语义分割模型，判断道路可行驶区域、边界和复杂路况特征。与此同时，系统结合 IMU、GPS 和毫米波雷达等传感器数据，对车辆姿态、行驶速度、前方目标距离和相对运动状态进行综合分析。

在此基础上，核心推理层将视觉感知结果与传感器状态数据统一输入风险融合模块，推理得到障碍物风险、距离风险、姿态稳定性风险和速度风险等子项结果，并进一步计算综合风险评分，最终输出低、中、高三级风险等级，为震动马达反馈和前端可视化显示提供决策依据。

3.3.3 本地反馈与云端监管

(1) 数据流向

多模态风险融合网络在每一帧融合数据到达后，计算综合风险评分，并生成对应的风险等级。上述结果与多源数据被统一写入线程安全的 Dashboard 状态池，状态池通过递增版本号标识数据更新，便于下游模块实时获取最新状态。

从状态池出发，系统数据主要分为三路输出：一路传递至马达控制模块，通过 I2C 接口驱动 DRV2605 震动马达产生触觉预警；一路推送至网页前端，使管理人员能够通过局域网实时查看骑行画面、风险评分、预警等级和传感器状态；另一路将关键骑行数据上传至云端数据库进行留存。

通过这种设计，系统将风险判断、本地预警、网页实时监控、云端数据留存和服务器视频保存连接起来，为骑行安全监测和事故复盘提供支持。




图 3-10 输出数据流向图

(2) 基于 WebSocket 的 Web 可视化

本系统以 WebSocket 长连接替代了 HTTP 轮询。若使用传统 HTTP 轮询，浏览器需定时发起请求并经历完整的请求-响应流程，而大部分请求返回的数据与上一轮并无差异，既产生大量无效网络开销，又因每轮 HTTP 握手头部消耗额外带宽，与后端同步运行的 MJPEG 视频流争抢有限资源。

因此，本系统以 WebSocket 长连接替代轮询：前端页面加载时与 /ws/state 端点建立连接；服务端以约 200 ms 为周期检测状态池版本号，仅在版本变更时推送纯 JSON 状态数据（约 300 字节），无变化时保持静默，与视频流之间几乎不存在带宽冲突；前端仅在收到推送时才执行 DOM 更新，空闲时段 CPU 消耗极低。




图 3-11 WebSocket 架构图

前端仪表盘由静态 HTML 页面实现，无需安装客户端依赖，浏览器直接访问即可使用。页面左侧以 MJPEG 视频流展示摄像头实时画面（包含语义分割掩膜叠加和检测框绘制），右侧面板按卡片分区显示：综合风险评分与等级、四项风险分量柱状图、传感器连线状态、IMU 实时姿态角、视觉感知结果和系统运行指标。

此外，页面内还建立了断线自动重连机制——当 WebSocket 意外断开时，前端在 2 秒后自动发起重连，服务恢复后即时接收最新状态，全程无需人工刷新页面，有效应对骑行时信号不稳定的情况。




图 3-12 前端界面效果图

通过骑行数据的服务端可视化，相关管理人员可以实时看到骑手的骑行状态，并及时发现可能出现的骑行事故，从而快速响应，及时地确保骑手的骑行安全。

(3) 骑行数据的云端存储

本系统使用部署在华为云 ECS 上的 openGauss 数据库保存骑行数据。DK-2500 边缘端完成数据采集和风险融合后，将关键结果上传到云端数据库。数据库中主要保存三类信息：一次骑行的基本记录、骑行过程中的状态数据，以及高风险事件。

同时，系统将关键骑行数据上传至云端数据库进行留存，包括骑手编号、时间戳、经纬度、速度、姿态状态、雷达距离、视觉识别结果、风险评分和预警触发记录等。对于骑行视频数据，系统不直接将完整视频持续上传至云端数据库，而是采用“普通片段滚动缓存、高风险片段标记留存”的方式处理：普通骑行视频仅在本地或服务器指定目录中短时缓存，并按时间窗口自动覆盖；当系统检测到高风险预警或疑似事故时，才对相关时间段的视频片段进行标记，并在数据库中保存视频路径、起止时间、对应骑行记录编号和风险等级等索引信息，便于后续进行骑行过程复盘和安全管理分析。

第四章 系统实现

4.1 前向视觉感知模型实现

前向视觉感知模块是系统获取道路环境信息的主要组成部分，负责从骑行方向图像中提取可通行路面区域和前方障碍目标，为后续功能模块提供基础输入。

考虑到本系统运行于 DK-2500 边缘计算平台，且服务于骑行安全预警场景，模型选型需优先满足端侧实时推理要求。因此，本系统采用“先满足实时性，再比较识别效果”的选型原则，优先选择结构轻量、部署链路成熟、适合 OpenVINO Runtime 推理的视觉模型。

4.1.1 可通行路面语义分割

可通行路面语义分割用于从前向图像中提取骑行方向上的路面区域，为系统判断前方通行空间和障碍物是否位于骑行路径提供基础。与汽车辅助驾驶中常见的车道级 drivable area 不同，电动车在实际通行过程中常出现在道路边缘、非机动车道、社区道路和混合交通区域等。因此，本系统将分割目标定义为整片可通行路面 road，而不是仅提取机动车道范围内的可行驶区域。

本系统采用 OpenVINO Open Model Zoo 提供的 road-segmentation-adas-0001 模型进行路面语义分割^[7]。该模型结构轻量，部署链路成熟，适合在 DK-2500 平台上进行端侧推理。模型对输入图像进行像素级分类后，系统提取其中的 road 类别，并将其转换为二值化路面掩膜 road mask。推理前，图像需经过尺寸调整、通道转换和归一化处理；推理后，系统取 road 类经 argmax 得到二值化路面掩膜，并对其进行轻量形态学处理（开运算去除孤立误判点、闭运算填补内部小空洞），以减少噪声和局部误分割对后续雷达路面门控判断的影响。

road mask 是可通行路面语义分割的主要输出结果，用于描述当前图像中的路面区域。该掩膜不仅可以反映骑行方向上的可通行空间，也可后续系统模块提供道路空间信息，为环境理解 and 功能扩展提供基础数据支持。




图 4-1 road adas 语义分割原理图

4.1.2 动态障碍目标检测

动态障碍目标检测用于识别前向图像中可能影响骑行安全的目标，并输出目标位置和检测置信度等环境信息。本系统采用类别无关检测方式，将行人、车辆、非机动车及其他可能阻挡骑行路径的目标统一定义为 **obstacle**。该设计更关注障碍物的空间风险特征。对于电动车骑行而言，目标是否危险主要取决于其位置、尺度、距离和接近趋势。该设计能够减少复杂类别划分带来的误差影响，提高模型在复杂骑行场景下的稳定性和泛化能力。

本系统采用轻量化的 YOLO26n 模型作为动态障碍目标检测模型^[8]。该模型属于 nano 级目标检测模型，结构较轻、推理速度较快，符合 DK-2500 端侧实时运行需求。模型输入为经过尺寸调整和归一化处理后的前向图像，输出为障碍目标的检测框、置信度和类别标记。由于本系统采用单类 **obstacle** 检测方式，模型输出的类别主要用于表示目标是否属于前向障碍物，检测框位置和置信度则作为后续风险计算的主要输入。

为提高模型对骑行场景中行人、车辆和两轮车目标的适应能力，本系统在初始模型基础上进行了驾驶场景数据微调。微调过程中严格区分训练数据与测试数据^[10]，避免测试样本进入训练过程；同时针对公开数据集中两轮车样本相对不足的问题，对含有自行车、电动车、摩托车等目标的样本进行补充和重采样，以增强模型对骑行场景关键目标的召回能力。经微调后的模型记为 YOLO26n-v2，并作为本系统动态障碍检测的部署版本。

在后处理阶段，系统根据置信度阈值筛除低可信度检测结果，保留最终障碍目标列表。每个检测结果包含目标框坐标、置信度以及 **obstacle** 标记，保留最终障碍目标列表。每个检测结果包含目标框坐标、置信度以及 **obstacle** 标记，用于描述障碍物在图像中的空间位置和检测结果。上述信息将与路面分割结果统一封装后输出。




图 4-2 YOLO26n-v2 目标检测原理图

4.1.3 基于 OpenVINO Runtime 的视觉模型端侧推理实现

为使视觉模型能够在 DK-2500 边缘计算平台上稳定运行，本系统采用 OpenVINO Runtime 对路面分割模型和目标检测模型进行端侧部署。整体部署链路包括模型导出、IR 转换、Runtime 加载和端侧推理四个环节^[9]。其中，路面分割模型直接采用 OpenVINO Open Model Zoo 提供的 IR 模型，目标检测模型则由 PyTorch 权重经 Ultralytics 一步导

出为 OpenVINO IR 格式^[9]。

Visual Models OpenVINO Edge Deployment Pipeline




图 4-3 视觉模型端侧推理部署流程图

OpenVINO IR 模型通常由 XML 结构文件和 BIN 权重文件组成，便于 Runtime 在 Intel 平台上统一加载与执行。模型转换完成后，系统以 FP32 版本作为精度基线，并根据端侧运行需求保留 FP16、INT8 等部署形式。不同精度版本的性能差异、量化策略和推理设备选择将在第五章系统优化部分进一步说明。

在端侧运行阶段，系统通过 OpenVINO Runtime 读取并编译 IR 模型，随后将预处理后的前向图像分别输入路面分割模型和目标检测模型。分割结果经类别选择生成 road mask，检测结果经置信度筛选和非极大值抑制得到障碍目标列表。两路输出被统一封装为视觉感知结果，包括路面掩膜、目标框坐标、置信度和 obstacle 标记。视觉模块最终输出统一的环境感知结果，为后续系统模块提供标准化输入接口。

4.1.4 视觉感知结果输出与接口设计

完成路面语义分割和障碍目标检测后，视觉模块需要向后续风险评估模块提供统一的环境感知结果。为降低模块间耦合，提高系统扩展性，系统对视觉输出结果进行了统一封装，使视觉模块能够作为独立功能单元运行。

表 4-1 视觉模块输出信息定义

输出信息	说明
road mask	可通行路面区域掩膜
bbox	障碍目标边界框坐标
confidence	目标检测置信度

系统将上述结果统一封装后传递至后续模块，实现视觉感知与风险评估之间的解耦设计。该接口既能够满足当前系统需求，也便于后续引入新的风险评估方法或多传感器融合模块。

4.2 风险融合网络的设计

为将视觉、毫米波雷达、IMU 和 GPS 的感知结果转化为可执行的预警信号，本系统设计轻量级多源风险融合网络 GT-MRFN。网络不直接输入原始图像，而是接收前级模块输出

的结构化特征，在 DK-2500 端侧输出风险等级和综合风险评分，结果直接用于马达反馈、Dashboard 显示和数据库留存。

4.2.1 多源输入特征构建

融合网络输入包括四类信息：视觉特征包括行人数量、车辆数量、障碍物数量、可通行区域比例和视觉风险值；雷达特征包括最近目标距离、相对速度、目标置信度和 TTC；IMU 特征包括姿态角、加速度、角速度、急刹评分、颠簸评分和侧倾评分；GPS 特征包括当前速度和定位有效状态。上述数据均来自系统已接入的传感器和感知模块，不额外增加硬件负担。

为避免距离、速度、姿态角等特征量纲不同对网络训练造成影响，连续型特征在输入前进行标准化处理：

$$\hat{x} * t^k = \frac{x * t^k - \mu^k}{\sigma^k} \quad (4-1)$$

其中， x_t^k 为第 k 类模态的原始特征， μ^k 和 σ^k 由训练集统计得到。端侧部署时继续使用同一组标准化参数，保证训练和推理输入一致。

雷达接近风险采用 TTC 表示：

$$TTC = \begin{cases} \frac{d}{-v_{rel}}, & v_{rel} < 0 \\ +\infty, & v_{rel} \geq 0 \end{cases} \quad (4-2)$$

其中， d 为目标距离， v_{rel} 为相对速度。当目标正在接近时，TTC 越小，骑手可反应时间越短，风险越高。系统同时为每路传感器设置有效性标志，用于区分正常数据、短时缺失和设备异常。雷达“无目标”只表示前方暂未检测到障碍，不等同于雷达失效。

4.2.2 时间对齐与缺失数据处理

由于各传感器采样频率不同，系统以主循环时刻为基准，从缓存中选取每一路最近的数据帧，组成当前融合输入。若某一路数据超过允许时间窗，则使用默认值填充，并将该路有效性标志置为无效。该处理方式能够适应相机、雷达、IMU 和 GPS 更新频率不同的问题，也能避免单路传感器短时丢帧导致系统中断。

4.2.3 风险融合网络结构

GT-MRFN 由单模态编码、短时序建模、门控融合和风险输出四部分组成，整体结构如图 4-4 所示。




图 4-4 风险融合网络架构图

单模态编码层分别处理视觉、雷达、IMU 和 GPS 特征，将不同来源的数据映射到统一特征空间，避免不同物理意义的数据直接拼接造成干扰。短时序建模层采用轻量化

TCN，对最近若干帧数据进行建模，用于捕捉目标持续接近、车辆急刹、车身侧倾等短时变化^[14]。相比循环神经网络，TCN 结构更简单，并行效率更高，更适合端侧实时推理^[14]。




图 4-5 TCN 短时序建模图

门控融合层根据当前场景和传感器有效性动态调整各模态权重^[15]。当前方目标距离缩短或 TTC 减小时，雷达权重提高；视觉检测到行人、车辆或通行区域变窄时，视觉权重提高；车辆急刹、颠簸或侧倾时，IMU 权重提高；速度较高时，GPS 速度特征的影响增强。若某一路传感器无效，其权重会被抑制，避免异常数据影响最终判断^[15]。




图 4-6 门控注意力融合图

网络输出低风险、中风险和高风险三类概率：

$$p_t = [p_t^{low}, p_t^{medium}, p_t^{high}] \quad (4-3)$$

风险等级由最大概率对应类别确定，综合风险评分由三类概率加权得到：

$$s_t = 0 \cdot p_t^{low} + 0.5 \cdot p_t^{medium} + 1.0 \cdot p_t^{high} \quad (4-4)$$

其中，风险等级用于马达分级预警，风险评分用于前端连续显示、风险趋势记录和数据库留存。也就是说，连续评分不是额外独立输出分支，而是由分类概率换算得到的统一量化结果，避免“评分回归”和“等级分类”两套逻辑在部署阶段相互冲突。

考虑到安全预警任务中漏报代价高于误报，本系统在 GT-MRFN 学习式风险判断之外加入规则兜底机制。最终风险取模型风险与规则风险的较大值： $R_final = \max(R_model,$

R_rule)。其中, R_rule 由雷达距离、相对速度、TTC、急刹和侧倾等安全阈值计算得到。当雷达检测到前方目标距离过近或 TTC 低于安全阈值时,即使视觉模型置信度较低,系统也会提升最终风险等级,避免单一模型漏检导致预警失效。

4.2.4 小结

GT-MRFN 采用中间层融合方式,将视觉、雷达、IMU 和 GPS 转化为低维结构化特征后再融合。该方案计算量小、输入清晰、可解释性较强,适合在 DK-2500 上与视觉推理、传感器读取和前端显示并行运行。

4.3 风险融合网络训练与部署

4.3.1 风险样本构建与数据集划分

训练样本来自完整骑行片段。系统同步记录前向视频、雷达数据、IMU 数据、GPS 数据和统一时间戳,再按固定时间窗口生成样本。原型验证阶段共构建 2400 个滑动窗口样本,其中低风险 1280 个、中风险 720 个、高风险 400 个。标签采用“规则伪标签+人工复核”的方式得到:先根据 TTC、目标距离、可通行区域比例、车速、急刹评分和侧倾评分生成初始标签,再结合视频画面和传感器曲线复核中高风险及边界样本。

表 4-2 风险等级标注依据表

风险等级	典型场景	判断依据
低风险	道路畅通、无近距离障碍、骑行状态稳定	前方无明显障碍,或目标距离较远, TTC 高于安全阈值, 车身姿态稳定
中风险	前方存在障碍、道路环境复杂、姿态或速度出现波动	前方存在行人、车辆或障碍物, 目标距离缩短但仍有一定避让时间, 或出现轻微急刹/颠簸/侧倾
高风险	前车急停、行人横穿、近距离障碍快速接近、急刹或明显侧倾	目标距离快速缩短、TTC 低于安全阈值、前车急停、行人横穿, 或车身姿态发生剧烈变化

数据集按完整骑行片段或路线划分为训练集、验证集和测试集,比例为 7:2:1。同一次骑行数据只进入一个集合,避免相邻窗口同时出现在训练集和测试集中造成评估结果虚高。每个样本由两名成员独立复核;若标注结果不一致,则由第三名成员结合视频画面、雷达距离曲线和 IMU 姿态变化确定最终标签。

4.3.2 网络训练策略

GT-MRFN 的训练目标为低、中、高三分类,损失函数采用加权交叉熵:

$$\mathcal{L} * cls = -\sum * c = 1^3 w_c y_c \log(p_c) \quad (4-4)$$

其中, y_c 为真实标签, p_c 为网络输出概率, w_c 为类别权重。由于低风险样本通常多于中高风险样本,训练时适当提高中风险和高风险样本权重,减少模型长期偏向低风险输出的情况。

训练过程中加入模态缺失增强,随机屏蔽部分传感器特征并同步修改有效性标志,用于模拟视觉遮挡、雷达短时异常、GPS 无效等真实情况。训练参数设置为学习率 0.001、

批大小 64、最大 100 轮，优化器采用 Adam。训练完成后保存最优模型权重、标准化参数和输入特征配置，测试集仅用于最终评估。

4.3.3 端侧部署与功能验证

训练完成后，模型导出为 ONNX，并转换为 OpenVINO IR 格式部署到 DK-2500。端侧程序启动时加载模型文件、标准化参数和输入特征配置使端侧输入格式和标准化参数与训练阶段保持一致。

端侧运行流程为：传感器读取模块采集数据，视觉模型输出目标和道路特征，同步模块构建融合帧，预处理模块完成标准化，GT-MRFN 输出风险概率、风险等级和风险评分，最终传给马达控制模块、Dashboard 前端和数据库记录模块。

功能验证重点检查模型能否正常加载、输入维度是否一致、单帧推理耗时是否满足主循环要求、传感器短时失效时是否继续输出、风险等级是否能够触发震动反馈并显示在前端。

通过上述流程，GT-MRFN 被嵌入“传感器输入—特征标准化—融合推理—风险等级输出—马达反馈/前端展示/数据留存”的完整闭环中，能够在现有硬件和软件框架下落地运行。

第五章 系统优化

为实现骑行场景下的低延迟前向安全预警，本系统在完成感知模型选型与多模态融合网络设计的基础上，从边缘计算架构、神经网络推理和异构资源调度三个层面进行了系统性优化。

5.1 边缘计算优化

5.1.1 多模态数据并行处理架构

骑行安全预警系统需要同时处理高清摄像头、毫米波雷达、IMU 和 GPS 四类传感器的数据，且视觉推理、雷达解析和姿态监测需并发运行。若采用串行处理方式，各模块依次占用 CPU 资源，会导致数据积压和响应延迟增加。为此，本系统采用多线程并行处理架构，将传感器数据读取、数据预处理、模型推理和风险融合分配至不同线程，通过生产者-消费者模型实现数据流的有序传递。

具体地，系统为每类传感器分配独立读取线程，摄像头图像、雷达目标、IMU 姿态和 GPS 速度数据在各自线程中完成采集与初级解析后，统一写入线程安全的数据缓存池。推理线程从缓存池中获取最新数据帧，完成多源数据时间同步后，将图像数据送入视觉模型执行推理，同时将结构化传感器数据送入风险融合网络。通过这种并行设计，CPU 的四类核心资源（性能核与能效核）可得到较为充分的利用，减少单一线程阻塞导致整体延迟增加，使系统能够在 DK-2500 平台上稳定运行多模态感知、推理与决策任务。

此外，系统采用流水线设计进一步隐藏数据采集与推理之间的等待时间。摄像头以 30fps 采集图像，推理线程与采集线程并行工作，当前帧推理过程中下一帧数据可同步完成采集与预处理，有效降低了端到端响应延迟，使前向安全预警系统在持续运行中保持较高的实时性。

5.1.2 异构计算资源协同调度

DK-2500 平台搭载的 Core Ultra 5 225U 处理器集成了 CPU、GPU 和 NPU 三种计算单元。针对不同计算任务的特点，本系统采用异构资源协同调度策略：

在计算密集且适合并行加速的视觉推理任务（目标检测与语义分割）中，系统通过 OpenVINO Runtime 的设备选择机制，将视觉模型部署至 GPU 和 NPU 等专用加速单元，显著降低推理延迟^[6]；对于结构化特征处理、风险融合网络推理、传感器数据解析和系统调度等逻辑控制任务，系统将网络部署至 CPU，利用其通用计算能力完成轻量级推理与任务分发。

在异构调度策略中，目标检测和语义分割模型分别部署在 NPU 和 GPU 两个加速单元上。由于二者处理的是同一帧图像，且 NPU 和 GPU 互不占用对方计算资源，两个模型可以并行执行推理。具体地，当一帧图像完成预处理后，系统同时将图像数据分发至 NPU 和 GPU——NPU 执行目标检测推理，GPU 执行语义分割推理。通过这种任务级并行调度推理，能够充分发挥资源优势，显著提升了整体处理效率。

通过上述异构协同调度，系统在保持较低 CPU 占用率的同时，实现了多视觉模型与多传感器数据的高效并发处理，为端侧实时预警提供了稳定的计算基础。

5.2 神经网络加速优化

5.2.1 模型量化与精度-性能权衡

为降低端侧推理延迟和内存占用，本系统对目标检测模型 YOLO26n-v2 进行了 INT8 量化处理。量化通过 OpenVINO 的 Neural Network Compression Framework 完成，将模型权重和激活值从 32 位浮点数映射为 8 位整数，减少模型体积和计算量^[16]。

量化后模型在 BDD100K 测试集上的 mAP@0.5 从 65.32% 降至 64.99%，仅下降 0.33 个百分点，精度损失较小；推理延迟从 15.85ms 降至 7.34ms，降低 53.7%；FPS 从 63.08 提升至 136.29，提升 116.1%。测试结果表明，INT8 量化在保持检测精度的同时大幅提升了推理速度，是端侧部署的有效手段。

对于道路分割模型 road-segmentation-adas-0001，INT8 量化后 IoU 从 65.38% 下降至 57.04%，下降 8.34 个百分点，精度损失较大，推测与分割任务对特征图细粒度信息更敏感有关。因此，分割模型保持 FP16 精度部署，在保持与 FP32 基本一致精度的前提下，利用 GPU 半精度计算能力提升推理效率。

5.2.2 基于 OpenVINO 的图优化与算子融合

本系统视觉模型通过 OpenVINO Runtime 完成端侧部署，OpenVINO 在模型加载过程中自动对计算图进行优化，主要优化手段包括^[16]：

算子融合：将卷积层、批归一化层和激活函数层（Conv+BN+ReLU）融合为单一操作，减少中间张量的内存读写次数和内核启动开销。对于 YOLO26n 中大量存在的卷积模块，算子融合可有效降低推理延迟。

内存复用：OpenVINO 在编译模型时对中间激活张量进行内存分配优化，复用不同层之间不再需要的缓存空间，降低峰值内存占用，减少内存分配与释放的开销。

布局优化：根据目标硬件（GPU/NPU）的特性，自动调整张量的内存布局格式，使其更适配底层计算引擎的访存模式，提高缓存命中率和计算效率。

通过上述优化，OpenVINO 相比 PyTorch 原生推理实现约 1.93 倍加速，FPS 提升约 1 倍，验证了图优化与算子融合策略在端侧部署中的有效性。

5.2.3 内存零拷贝与数据传输优化

在 DK-2500 平台上，CPU 与 GPU 共享物理内存，数据传输过程可减少不必要的数据拷贝即可在不同计算单元之间访问。基于此硬件特性，本系统采用零拷贝数据传输策略：

图像数据由摄像头读取后，直接存放于共享内存缓冲区，目标检测模型（NPU）与语义分割模型（GPU）可直接访问同一块内存地址中的数据，无需将数据从 CPU 内存拷贝至设备内存。这一设计大幅降低了数据搬运开销，尤其在双模型同时推理的场景中，避免了同一图像数据两次拷贝的冗余操作，有效减少了端到端处理延迟。

同时，系统在数据预处理阶段采用 OpenVINO 提供的零拷贝 Tensor 接口，直接将预处理后的图像数据以 OpenVINO 张量格式传递至推理后端，避免额外的格式转换与内存复制操作。上述优化措施使 DK-2500 的 CPU 与加速单元之间的数据传输开销降至最低，进一步提升了全链路响应速度。

通过上述边缘计算架构优化、异构协同调度、模型量化压缩以及内存零拷贝等策略的综合应用，本系统在 DK-2500 平台上实现了视觉感知推理与多模态融合决策的高效运行，为后续实车部署奠定了性能基础。

第六章 系统测试

为了全面验证本系统在真实骑行场景下的性能表现与可靠性，本章从模型精度、推理性能与硬件选型等多个维度对系统进行了系统性的测试与分析。所有测试均在英特尔 DK-2500 开发套件上完成。

6.1 测试方案设计

本章测试遵循“先精度后性能、先模型后部署”的递进逻辑，按以下顺序逐层推进：

- (1) 目标检测模型精度评估（数据集、微调效果）；
- (2) 目标检测精度与性能权衡（FP32/FP16/INT8）；
- (3) 目标检测硬件后端选型（CPU/GPU/NPU/AUTO）；
- (4) 道路分割模型精度评估（数据集、模型选型）；
- (5) 道路分割精度与硬件选型（精度对比、后端选型）；
- (6) 推理框架优化验证（PyTorch vs OpenVINO）；
- (7) 多模态融合有效性验证（仅视觉 vs 视觉+雷达+IMU+GPS）。
- (8) 端到端风险预警有效性验证（预警召回率、漏报率、平均预警提前量、P95 响应时间和连续运行稳定性）。

6.2 目标检测模型测试

6.2.1 目标检测模型精度评估

目标检测模块采用 YOLO26n-v2，输入 640×640，置信度阈值 0.15，在 BDD100K、IDD 和 DAWN 三个数据集上完成精度测试^[10]。为验证微调策略有效性，将微调版与原版在 BDD100K 上进行对比。

表 6-1 YOLO26n-v2 在不同数据集上的检测精度（FP32，CPU）

数据集	图片数	精确率(%)	召回率(%)	F1-score(%)
BDD100K	1500	79.43	53.86	64.18
IDD	500	73.80	30.07	42.73
DAWN	300	82.17	45.82	58.82



图 6-1 左侧为原图，右侧为 YOLO26n-v2 目标识别测试结果图

表 6-2 YOLO26n-v2 与 YOLO26n 原版在 BDD100K 上的精度对比 (FP32)

测试子集	图片数	模型版本	mAP@0.5(%)	精确率(%)	召回率(%)
子集	1500	YOLO26n 原版	46.88	81.95	31.07
子集	1500	YOLO26n-v2	65.32	79.43	53.86
夜间场景	456	YOLO26n 原版	37.68	79.42	21.97
夜间场景	456	YOLO26n-v2	63.44	77.17	51.37



图 6-2 夜间场景测试结果图

测试分析：YOLO26n-v2 在测试集上 mAP@0.5 达 65.32%，相比原版（46.88%）提升 18.44 个百分点；召回率从 31.07% 提升至 53.86%（+22.79 个百分点），说明微调策略对骑行场景目标识别有明显改善。在夜间场景下，YOLO26n-v2 mAP@0.5 为 63.44%（原版 37.68%，+25.76 个百分点），召回率为 51.37%（原版 21.97%，+29.40 个百分点），微调策略在弱光场景下收益较明显。需要指出的是，视觉召回率仍不足以单独支撑安全预警，因此系统进一步引入毫米波雷达距离、IMU 姿态和 GPS 速度信息，通过多模式融合降低单一视觉漏检带来的安全风险。

6.2.2 目标检测精度-性能权衡

评估不同精度配置对精度与推理性能的影响。精度测试在 GPU 后端完成，性能测试在 NPU 后端完成。

表 6-3 YOLO26n-v2 在不同精度下的性能与精度对比

精度	mAP@0.5(%)	F1-score(%)	平均延迟(ms)	FPS
FP32	65.32	64.18	15.85	63.08
FP16	65.32	64.18	16.41	60.93
INT8	64.99	63.75	7.34	136.29

测试分析：INT8 量化后 mAP@0.5 仅下降 0.33 个百分点（65.32%→64.99%），精度损失极小。推理性能提升显著：平均延迟降低 53.7%（15.85ms→7.34ms），FPS 提升 116.1%（63.08→136.29）。综合权衡，INT8 为最优精度选择。

6.2.3 目标检测硬件后端选型

在确定 INT8 精度后，评估四种硬件后端的推理性能，样本量 2278 张。

表 6-4 不同硬件后端目标检测推理性能对比 (INT8 精度)

设备后端	平均延迟(ms)	P95 延迟(ms)	FPS	标准差(ms)
CPU	34.85	45.80	28.69	±5.69

续表 6-4

设备后端	平均延迟(ms)	P95 延迟(ms)	FPS	标准差(ms)
GPU	15.96	18.13	62.65	±1.11
NPU	10.93	12.57	91.48	±0.81
AUTO	18.21	20.35	54.90	±1.08

测试分析：NPU 以平均延迟 10.93ms、FPS 91.48 显著优于其他后端，相比 CPU 实现约 3.2 倍加速，延迟标准差仅 0.81ms，推理一致性最好。目标检测模块最终方案：INT8 精度 + NPU 后端。

6.3 道路分割模型测试

6.3.1 道路分割模型精度与选型

道路分割模块采用 OpenVINO 官方预训练模型 road-segmentation-adas，输入 1024×1024，在 BDD100K、IDD、ACDC 和 Cityscapes 上完成精度验证^{[7][10][11][12]}。为验证选型合理性，将 PIDNet-S 作为对比基线^[13]。

表 6-5 road-adas 在不同数据集上的分割精度（FP32，CPU）

数据集	图片数	道路 IoU(%)	像素准确率(%)
BDD100K	200	65.40	90.39
IDD	200	26.94	76.96
ACDC	100	90.16	98.44
Cityscapes	200	73.89	90.96




图 6-3 左侧为给定标注图，右侧为 adas 语义分割测试结果图

表 6-6 road-adas 与 PIDNet-S 性能对比（CPU，FP32）

数据集	模型	道路 IoU(%)	平均延迟(ms)	FPS
BDD100K	road-adas	65.40	135.78	7.4
BDD100K	PIDNet-S	74.06	210.68	4.7
Cityscapes	road-adas	73.89	135.60	7.4
Cityscapes	PIDNet-S	85.50	188.44	5.3




图 6-4 左到右分别为测试结果图

测试分析：模型在 ACDC 和 Cityscapes 上表现较高，IoU 分别达 90.16%和 73.89%；BDD100K 上 IoU 为 65.40%。IDD 数据集因领域迁移 IoU 较低（26.94%），属预期现象。PIDNet-S 精度优于 road-adas，但推理延迟高约 36%~38%，FPS 低约 57%~63%，road-adas 更适合实时部署。

6.3.2 分割精度-性能权衡与硬件选型

表 6-7 不同精度下分割模型在 BDD100K 上的精度与推理性能

精度	道路 IoU(%)	像素准确率(%)	平均延迟(ms)	设备后 端
FP32	65.38	90.38	68.65	GPU
FP16	65.38	90.38	68.65	GPU
INT8	57.04	88.00	64.37	GPU

表 6-8 不同硬件后端道路分割性能对比（跨数据集均值，FP16 精度）

设备后 端	平均延迟 (ms)	FPS	CPU 占用率(%)	内存占用 (MB)
CPU	130.85	7.65	3.02	897.44
GPU	68.65	14.6	4.02	1061.20
NPU	91.43	10.95	4.17	1068.64
AUTO	78.66	12.78	3.89	1197.79

测试分析：分割模型 FP32 与 FP16 精度基本一致，INT8 量化后 IoU 下降 8.34 个百分点，精度损失较大，且平均延迟提升极小，不适宜量化。GPU 在 FP16 精度下表现最优（68.65ms，14.6 FPS），相比 CPU 实现约 1.9 倍加速。道路分割模块最终方案：FP16 精度 + GPU 后端。

6.4 推理框架优化验证

对比 PyTorch 原生与 OpenVINO 优化的性能差异，使用 YOLO26n-v2，GPU，FP32。

表 6-9 PyTorch 与 OpenVINO 推理性能对比

数据集	推理框架	平均延迟(ms)	FPS	加速比
DAWN	PyTorch	54.96	18.20	—
DAWN	OpenVINO	27.65	36.16	1.99×
BDD100K	PyTorch	53.70	18.62	—
BDD100K	OpenVINO	27.82	35.94	1.93×
IDD	PyTorch	54.55	18.33	—

续表 6-9

数据集	推理框架	平均延迟(ms)	FPS	加速比
IDD	OpenVINO	27.08	36.93	2.01×




图 6-5 PyTorch 与 OpenVINO 推理性能对比

测试分析：OpenVINO 在三个数据集上均实现了约 1.93~2.01 倍的推理加速，FPS 提升约 93%~101%，验证了 OpenVINO 在 DK-2500 平台上的优化有效性。

6.5 多模态融合有效性验证

为进一步验证各类传感器对风险判断的实际贡献，本节在仅视觉、仅雷达、视觉+雷达、视觉+雷达+IMU 和完整多模态方案之间进行消融对比。实验不再只比较误报率和漏报率，还统计高风险召回率，以避免将多模态融合简单解释为硬件堆叠。测试场景由白天、弱光、逆光、遮挡、颠簸和目标接近等典型片段组成，各方案使用相同测试片段和统一标注结果。

表 6-10 多模态融合消融对比测试

测试方案	测试场景数	高风险召回率(%)	漏报率(%)	误报率(%)
Vision only	20	65.0	35.0	13.5
Radar only	20	70.0	30.0	11.8
Vision + Radar	20	80.0	20.0	10.2
Vision + Radar + IMU	20	80.0	20.0	9.6
Vision + Radar + IMU + GPS	20	85.0	15.0	8.8

测试分析：仅视觉方案在弱光、逆光和遮挡场景中容易出现漏检；仅雷达方案能够稳定提供距离和接近趋势，但缺少目标类别和道路语义信息。视觉与雷达组合后，高风险召

回率提升至 80.0%，漏报率下降至 20.0%；加入 IMU 后，急刹、侧倾和颠簸场景下的误判进一步减少；完整多模态方案召回率达到 85.0%，漏报率降至 15.0%，说明雷达、IMU 和 GPS 并非简单堆叠，而是在视觉不稳定、目标接近和车辆状态突变时提供了互补信息。

6.6 模块性能与初步系统响应指标汇总

表 6-11 模块性能与初步系统响应指标汇总

评估维度	测试结果
目标检测 mAP@0.5 (FP32 / INT8)	65.32% / 64.99%
目标检测 F1-score (FP32 / INT8)	64.18% / 63.75%
道路分割 IoU (BDD100K)	65.40%
道路分割 IoU (Cityscapes / ACDC)	73.89% / 90.16%
目标检测推理延迟 (NPU, INT8)	10.93 ms
道路分割推理延迟 (GPU, FP16)	68.65 ms
完整多模态高风险召回率	85.0%
完整多模态漏报率	15.0%
核心处理链路平均响应时间	119.5 ms
完整全链路平均响应时间	约 158 ms

需要说明的是，表 6-12 中的指标仍以模块性能和初步系统响应为主，不能等同于完整安全预警效果。系统是否真正有效，还需要从“传感器采集—模型推理—风险融合—预警输出—骑手收到震动”的闭环过程进行验证。

表 6-12 全链路延迟分解测试结果

环节	平均延迟	P95 延迟
摄像头采集与预处理	24.0 ms	42 ms
目标检测	12.8 ms	22 ms
道路分割	78.5 ms	118 ms
雷达/IMU/GPS 解析	10.6 ms	18 ms
时间同步与状态缓存	7.9 ms	15 ms
风险融合与等级判断	5.7 ms	11 ms
马达控制输出	18.5 ms	32 ms
总响应时间	约 158 ms	约 258 ms

系统在 DK-2500 上实现了百毫秒级端侧闭环响应，典型全链路平均响应时间约为 158 ms，P95 响应时间约为 258 ms。考虑到骑行安全预警对延迟稳定性较敏感，本报告进一步统计了 P95 响应时间和连续运行延迟波动，以验证系统在长时间运行中的实时性稳定性。

6.7 端到端风险预警有效性验证

因此，本节不再仅从视觉模型精度评价系统，而是从骑行安全预警任务出发，统计系统在典型危险事件中的预警召回率、漏报率、误报频次、预警提前量和全链路响应时间，以验证系统是否能够在危险发生前提供有效提醒。

受项目开发周期、场地安全和实车测试条件限制，端到端风险预警测试采用受控场景复现与短时实车片段相结合的方式。测试重点不在于证明系统已覆盖所有开放道路情况，而是验证系统在典型前向风险场景下能否完成“感知—融合—预警”的闭环响应。各类

场景均保持相同的风险判定规则和预警阈值，测试结果主要用于评价系统原型的可行性、实时性和多模态融合有效性。

表 6-13 端到端风险预警效果测试结果

场景	样本数	成功预警数	高风险召回率	漏报率	平均预警提前量	P95 响应时间
前方行人横穿	20	16	80.0%	20.0%	1.05 s	252 ms
前车急停	20	16	80.0%	20.0%	0.88 s	263 ms
障碍物逼近	20	17	85.0%	15.0%	1.21 s	246 ms
弱光/逆光	20	15	75.0%	25.0%	0.94 s	281 ms

在 30 分钟正常骑行片段中，系统误报频次为 0.07 次/分钟；连续运行 60 分钟未出现传感器线程退出、WebSocket 断连后无法恢复或主程序异常退出。端到端测试表明，在本报告设置的典型前向风险场景下，系统具备提前触发震动预警的能力，完整链路平均响应时间约为 158 ms，P95 响应时间处于 246~281 ms 范围内，能够满足原型系统的初步验证要求。

6.8 测试结论

本章对目标检测与道路分割两个核心模块进行了系统性的测试与分析，主要结论如下：

(1) 目标检测模块：YOLO26n-v2 在 BDD100K 测试集上 mAP@0.5 达 65.32%，相比原版提升 18.44 个百分点；召回率从 31.07% 提升至 53.86%，微调策略效果明显。与此同时，该召回率也说明单视觉检测仍可能在弱光、遮挡或小目标场景中漏检，因此本系统不将视觉检测作为唯一预警依据，而是通过雷达、IMU 和 GPS 信息进行融合补偿。INT8 量化后 mAP@0.5 仅下降 0.33 个百分点；NPU 在 INT8 精度下表现较优（10.93 ms，91.48 FPS），最终方案为 INT8 精度 + NPU 后端。

(2) 道路分割模块：road-segmentation-adas-0001 在 BDD100K 上 IoU 为 65.40%，Cityscapes 上为 73.89%，ACDC 上达 90.16%；但在 IDD 上 IoU 明显降低，说明跨区域泛化仍是路面分割的主要不足。系统因此将 road mask 作为视觉语义特征之一，而不是单独作为安全判断依据；当分割置信度不足时，融合模块降低视觉权重，并结合雷达距离、TTC、姿态变化和速度信息进行判断。综合实时性和精度后，最终方案为 FP16 精度 + GPU 后端。

(3) 推理框架优化：OpenVINO 相比 PyTorch 原生推理实现约 1.93~2.01 倍加速，FPS 提升 93%~101%，验证了 OpenVINO 在 DK-2500 平台上的优化有效性。异构调度方面，目标检测与道路分割分别在 NPU 和 GPU 上并行推理，充分发挥了 DK-2500 异构计算平台的资源优势。

(4) 多模态融合有效性：消融实验表明，完整多模态方案相比仅视觉方案具有更高的高风险召回率和更低的漏报率。雷达主要补充距离和接近趋势，IMU 主要补充急刹、侧倾和颠簸状态，GPS 速度用于判断风险强度和预警优先级。端到端测试结果表明，在本报告设置的典型测试场景中，系统能够较稳定地完成前向风险感知、融合判断和震动预警输出。测试结果说明该原型系统具备初步实时预警能力，但其在更长时间、更复杂开放道路环境下的鲁棒性仍需通过后续扩大样本规模和实车测试进一步验证。

第七章 总结与展望

7.1 项目总结

本项目围绕外卖骑手因频繁查看手机导致前向注意力不足的核心安全痛点，设计并实现了一套基于边缘 AI 的骑手前向安全预警辅助系统。系统以英特尔 DK-2500 开发套件为边缘计算平台，融合高清摄像头、毫米波雷达、IMU 姿态传感器和 GPS 模块，构建了多源协同感知、端侧智能推理、分级触觉预警和云端数据监管的完整闭环。

综合测试结果表明，系统在目标检测、道路分割、边缘推理和典型风险场景预警方面达到了原型阶段的预期验证目标，初步证明了边缘 AI 技术在骑手前向安全预警场景中的可行性。

7.2 未来展望

尽管本系统已实现预期功能，但仍存在进一步优化和扩展的空间：

（1）**响应时间优化：**当前系统核心处理链路平均响应时间约 119.5 ms，完整全链路平均响应时间约 158 ms，道路分割推理仍是主要瓶颈。后续可探索更轻量的分割网络，进一步缩短端到端延迟。

（2）**夜间感知增强：**当前系统在夜间场景下检测召回率仍有提升空间，后续可考虑引入红外摄像头或低照度相机，提升弱光环境下的感知能力。

（3）**场景扩展：**当前系统主要面向城市配送骑行场景，后续可适配校园巡逻车、园区低速接驳车、共享电动车等更多短途移动安全场景。

（4）**平台集成：**系统已具备云端数据留存和 Web 监管能力，后续可与配送平台的管理系统对接，实现大规模骑手的安全监控与风险统计，为平台安全管理和骑手权益保障提供数据支持。

综合来看，本项目为城市短途出行安全防护提供了一种低延迟、多模态、可扩展的技术方案，具有良好的应用前景和社会价值。

参考文献

- [1] 韩鑫. 即时配送“跑”向万亿元大市场[N]. 人民日报, 2025-02-12(18).
- [2] 最高人民检察院. “赶时间的人”——外卖骑手权益保障问题引起最高检关注[EB/OL]. 2023-05-04.
- [3] Garmin. Varia™ Rearview Radar[EB/OL]. [2026-06-29].
- [4] 深圳市卓信创驰技术有限公司. DK-2500 开发套件规格书[R].
- [5] Intel Corporation. Intel® Core™ Ultra 5 Processor 225U: specifications[EB/OL]. [2026-06-29].
- [6] Intel Corporation. Supported Devices—OpenVINO™ documentation[EB/OL]. [2026-06-29].
- [7] Intel Corporation. road-segmentation-adas-0001—OpenVINO™ documentation[EB/OL]. [2026-06-29].
- [8] REDMON J, DIVVALA S, GIRSHICK R, et al. You Only Look Once: Unified, Real-Time Object Detection[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 779-788.
- [9] Ultralytics. Intel OpenVINO Export[EB/OL]. [2026-06-29].
- [10] YU F, CHEN H F, WANG X, et al. BDD100K: A Diverse Driving Dataset for Heterogeneous Multitask Learning[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 2636-2645.
- [11] CORDTS M, OMRAN M, RAMOS S, et al. The Cityscapes Dataset for Semantic Urban Scene Understanding[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 3213-3223.
- [12] SAKARIDIS C, DAI D, VAN GOOL L. ACDC: The Adverse Conditions Dataset with Correspondences for Semantic Driving Scene Understanding[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 10765-10775.
- [13] XU J C, XIONG Z X, BHATTACHARYYA S P. PIDNet: A Real-Time Semantic Segmentation Network Inspired by PID Controllers[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 19529-19539.
- [14] BAI S J, KOLTER J Z, KOLTUN V. An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling[J/OL]. arXiv:1803.01271, 2018.
- [15] AREVALO J, SOLÓRIO T, MONTES-Y-GÓMEZ M, et al. Gated Multimodal Units for Information Fusion[J/OL]. arXiv:1702.01992, 2017.
- [16] Intel Corporation. Model Optimization Guide—OpenVINO™ documentation[EB/OL]. [2026-06-29].
- [17] WitMotion. AHRS IMU Sensor | WT61C: Datasheet[EB/OL]. [2026-06-29].
- [18] u-blox AG. NEO-M8: u-blox M8 Concurrent GNSS Modules: Data Sheet[R/OL]. [2026-06-29].
- [19] Logitech. Logitech HD Pro Webcam C910 Technical Specifications[EB/OL]. [2026-06-29].
- [20] Texas Instruments. DRV2605 Haptic Driver for ERM and LRA with Built-In Library and Smart-Loop Architecture: Datasheet[EB/OL]. 2018[2026-06-29].